

题目：基于深度学习的繁体字 **OCR** 识别系统设计与实现

一、背景与目标

繁体字（尤其是古籍中的手写或印刷繁体字）也面临识别困难、人工转写效率低的问题。本项目目标是开发一个端到端的繁体字 **OCR** 系统，能够从古籍图像中自动识别并转录为简体或繁体文本。

二、任务描述

1. **输入：** 包含繁体字的古籍页面图像（如《四库全书》片段、民国旧报纸、石刻拓片等）。
2. **输出：** 识别后的文本（简体或繁体均可，鼓励保留繁体+可选的简体对照）。
3. **要求：**
 - 支持至少 400 个常用繁体字的识别
 - 能处理一定程度的倾斜、噪声、光照不均
 - 提供简单的 Web 或命令行演示界面

三、技术路线建议（参考楔形文字项目）

繁体字 OCR 模块	可选工具/模型
图像预处理（去噪、二值化、倾斜校正）	OpenCV, PIL, 自适应阈值
OCR 识别模型（可微调或使用预训练模型）	PaddleOCR（简体预训练 + 繁体微调）、Tesseract、CRNN + CTC
构建繁体字数据集	开源数据集（如 CASIA-HWDB、ICDAR 2017）、自行爬取+标注
模型集成与后处理	语言模型纠错（如基于 N-gram 或 BERT 的繁体语言模型）

四、数据获取建议（可做简化版）

1. 公开数据集：

- CASIA-HWDB（手写汉字数据库，含繁体）
- ICPR MTWI（网络图像文字）
- 古籍数字图书馆（如“中国哲学书电子化计划”）提供的图像与文本对齐数据

2. 合成数据（适合学生快速实验）：

- 用繁体字体（如明体、楷体）在随机背景上生成文字图像
- 添加噪声、模糊、仿射变换
- 使用 PIL + numpy 或 imgaug 库生成

3. 标注工具：Labellmg、PPOCRLabel（PaddleOCR 配套）

五、评价指标

- 字符准确率 (**Character Accuracy**) = 正确识别的字符数 / 总字符数
- 整句准确率 (可选)
- 处理速度 (FPS)
- 模型大小 (便于部署)

六、预期成果 (可参照楔形文字项目的“质变”效果)

- 基础版: 对清晰印刷体繁体字识别准确率 > 85%
- 进阶版: 对古籍、手写体准确率 > 70%, 并实现光照/噪声鲁棒
- 创新版: 引入大模型后处理 (如用文心或 ChatGLM 纠正 OCR 错误), 或实现少样本学习快速适配新字体

七、参考资源

- **PaddleOCR** (文心衍生 OCR 工具): <https://github.com/PaddlePaddle/PaddleOCR>
- 微调教程: PaddleOCR 提供了完整的文本检测+识别微调流程
- 繁体字语言模型: 可以使用 OpenCC 进行繁简转换, 或训练一个基于 LSTM/Transformer 的纠错模型

八、挑战与思考题

1. 繁体字图像中哪些干扰最严重？如何设计类似的“剥离”方法？
2. 如果只有少量标注数据（如几百对图像-文本），如何借鉴 NabuOCR 的 33000 对数据训练思路？可以尝试哪些数据增强或预训练策略？
3. 繁体字中存在大量异体字、罕见字，如何让模型具备“不认识时主动询问或标注”的能力？
4. 试试看用端到端的 ViT（Vision Transformer）能否一步到位？